

Titanic Dataset 기반 Feature Engineering 파이프라인 비교 분석

머신러닝 성능 향상을 위한 전처리 및 변수 선택 전략 비교 보고서

GitHub 주소: 제출 시 본인 GitHub 저장소 URL 기입

1. 데이터셋 소개

본 과제에서는 Kaggle Titanic Dataset 형식의 공개 데이터를 사용하였다. 목표는 승객의 객실 등급, 성별, 나이, 운임, 가족 동반 여부 등의 정보를 바탕으로 생존 여부(Survived)를 예측하는 이진 분류 모델을 구축하는 것이다. 데이터는 총 891행, 12열로 구성되어 있으며, 최소 500개 이상 샘플 조건과 수치형/범주형 변수 포함 조건을 만족한다.

Rows	Columns	Target	Survival Rate
891	12	Survived	0.3838

컬럼 설명 표


Column	Description	Type
PassengerId	Passenger identifier	Identifier
Survived	Survival status: 0 = No, 1 = Yes	Target
Pclass	Ticket class: 1/2/3	Ordinal categorical / numeric
Name	Passenger name	Text
Sex	Passenger sex	Categorical
Age	Passenger age	Numeric
SibSp	Number of siblings/spouses aboard	Numeric
Parch	Number of parents/children aboard	Numeric
Ticket	Ticket number	Text
Fare	Passenger fare	Numeric
Cabin	Cabin number	Categorical/Text
Embarked	Port of embarkation	Categorical

2. 탐색적 데이터 분석(EDA)


EDA에서는 결측치 비율, 타겟 분포, 수치형 변수 분포, 이상치, 상관관계를 확인하였다. Cabin은 결측치가 매우 많고, Age도 상당한 결측치가 존재하므로 결측치 처리 전략 비교가 필요하다. Embarked는 결측치가 적어 최빈값 대체가 적절하다.

결측치 비율 요약

Column	missing_ratio_percent
Cabin	77.10%
Age	19.87%
Embarked	0.22%





타겟 변수는 사망(0)이 생존(1)보다 많아 약한 클래스 불균형이 존재한다. 따라서 Accuracy뿐 아니라 Precision, Recall, F1-score, ROC-AUC를 함께 사용하였다.



EDA 시각화 결과

Age와 Fare 분포를 확인한 결과, Fare는 오른쪽 꼬리가 긴 분포와 일부 고가 운임 이상치를 보인다. 이 때문에 이상치에 민감한 StandardScaler뿐 아니라 RobustScaler도 비교하였다.





3. Feature Engineering 과정

원본 변수만 사용할 경우 이름, 객실 번호, 티켓 번호 같은 문자열 변수를 모델이 직접 활용하기 어렵다. 따라서 Titanic 도메인 특성을 반영하여 다음 파생 변수를 생성하였다.

Derived Feature	Definition	Purpose
FamilySize	SibSp + Parch + 1	함께 탑승한 가족 규모 반영
IsAlone	FamilySize == 1	단독 탑승 여부 반영
FarePerPerson	Fare / FamilySize	가족 규모에 따른 1인당 운임 반영
Title	Name에서 Mr/Mrs/Miss 등 호칭 추출	성별/연령/사회적 지위 정보 일부 반영
CabinKnown	Cabin 결측 여부	객실 정보 존재 자체를 신호로 사용
Deck	Cabin 첫 글자	객실 구역 정보 반영
AgeGroup	Age를 구간화	연령대별 생존 패턴 반영

실험 조합



Experiment	Missing	Encoding	Scaling	Feature Selection	Description
Base	없음	없음	없음	없음	결측치 없는 기본 수치형 변수만 사용
Exp-1	Mean	One-Hot	StandardScaler	X	평균 대체 + 원핫 인코딩 + 표준화
Exp-2	Median	Label/Ordinal	MinMaxScaler	O	중앙값 대체 + 순서형 인코딩 + 변수 선택
Exp-3	Most Frequent	One-Hot	RobustScaler	O	최빈값 대체 + 원핫 인코딩 + Robust + 변수 선택

Base 실험은 원본 데이터를 완전히 그대로 사용하면 문자열 및 결측치로 인해 scikit-learn 모델 학습이 불가능하므로, 별도 고급 전처리 없이 결측치가 없는 기본 수치형 변수(Pclass, SibSp, Parch, Fare)만 사용한 기준선으로 정의하였다.

4. 모델 학습 및 성능 평가

모델은 Logistic Regression과 Random Forest를 비교하였다. Logistic Regression은 스케일링과 인코딩 영향을 보기 좋고, Random Forest는 비선형 패턴과 변수 중요도 확인에 적합하다. 평가는 train/test split(8:2, stratify=y, random_state=42) 기준으로 수행하였다.

Experiment	Model	Missing	Encoding	Scaling	Feature Selection	Accuracy	Precision	Recall	F1	ROC_AUC
Base	LogReg	none	none	none	X	0.6480	0.5625	0.3913	0.4615	0.6738
Base	RF	none	none	none	X	0.5922	0.4714	0.4783	0.4748	0.6452
Exp-1	LogReg	mean	onehot	standard	X	0.8436	0.8254	0.7536	0.7879	0.8740
Exp-1	RF	mean	onehot	standard	X	0.7989	0.7463	0.7246	0.7353	0.8316
Exp-2	LogReg	median	label	minmax	O	0.7821	0.7344	0.6812	0.7068	0.8381
Exp-2	RF	median	label	minmax	O	0.7821	0.7143	0.7246	0.7194	0.8341
Exp-3	LogReg	most_frequent	onehot	robust	O	0.8101	0.7869	0.6957	0.7385	0.8610
Exp-3	RF	most_frequent	onehot	robust	O	0.8156	0.7647	0.7536	0.7591	0.8303




5. Feature Selection 및 중요 변수 해석

Feature Selection은 SelectKBest(mutual_info_classif)를 사용하여 상위 10개 변수를 선택하였다. 또한 Random Forest Feature Importance를 이용해 변수 영향도를 시각화하였다.

Random Forest Feature Importance 상위 10개

feature	importance
Age	0.1443
FarePerPerson	0.1313
Fare	0.1275
Title_Mr	0.0907
Sex_male	0.0883
Sex_female	0.0820
Pclass	0.0471
FamilySize	0.0357
CabinKnown	0.0294
SibSp	0.0253



중요 변수는 Age, FarePerPerson, Fare, Title_Mr, Sex_male, Sex_female 등이었다. 이는 Titanic 데이터에서 성별, 연령, 운임, 사회적 호칭이 생존 가능성 예측에 중요한 정보를 제공한다는 것을 의미한다.

6. GridSearchCV 추가 실험

가산점 항목으로 Exp-3 + RandomForest 조합에 대해 GridSearchCV를 적용하였다. 탐색 대상은 n_estimators, max_depth, min_samples_split이며, ROC-AUC를 기준으로 교차검증하였다.

Experiment	Model	BestParams	CV_Best_ROC_AUC	Test_Accuracy	Test_Precision	Test_Recall	Test_F1	Test_ROC_AUC
Exp-3 + GridSearchCV	RF	{'clf__max_depth': 5, 'clf__min_samples_split': 2, 'clf__n_estimators': 100}	0.8737	0.8212	0.7846	0.7391	0.7612	0.8486

7. 최종 결론

실험 결과, 단순한 Base 모델보다 결측치 처리, 범주형 인코딩, 스케일링, 파생 변수 생성을 포함한 Feature Engineering 적용 모델의 성능이 전반적으로 높게 나타났다. 특히 Exp-1의 Logistic Regression은 Accuracy 0.8436, F1-score 0.7879, ROC-AUC 0.8740으로 가장 좋은 성능을 보였다. 이는 One-Hot Encoding이 Sex, Embarked, Title, Deck과 같은 명목형 변수의 정보를 효과적으로 반영했고, StandardScaler가 Logistic Regression의 학습 안정성에 기여했기 때문으로 해석된다.

One-Hot Encoding이 항상 좋은 것은 아니다. 범주 수가 많을 경우 차원이 증가하여 과적합이나 계산 비용 문제가 발생할 수 있다. 그러나 Titanic 데이터는 범주 수가 많지 않기 때문에 Label/Ordinal Encoding보다 One-Hot Encoding이 더 적합하게 작동했다.

Feature Selection은 모델을 단순화하고 해석 가능성을 높이는 장점이 있었지만, 본 실험에서는 전체 변수를 사용한 Exp-1 Logistic Regression이 가장 높은 ROC-AUC를 보였다. 따라서 변수 선택은 항상 성능 향상을 보장하지 않으며, 데이터 크기와 변수 구조, 모델 특성에 따라 효과가 달라진다.

스케일링은 모델별로 영향이 다르게 나타났다. Logistic Regression은 거리와 계수 기반 학습 특성상 스케일링의 영향을 크게 받았고, Random Forest는 트리 기반 모델이므로 스케일링 영향이 상대적으로 작았다. 최종적으로 Titanic 생존 예측 문제에서는 결측치 처리, 파생 변수 생성, 적절한 범주형 인코딩을 포함한 체계적인 Feature Engineering 파이프라인이 성능 향상에 실질적으로 기여함을 확인하였다.

제출 구성

File	Description
report/titanic_feature_engineering_report.pdf	최종 보고서 PDF
notebook/titanic_feature_engineering_executed.ipynb	실행 완료 노트북
src/pipeline_experiment.py	재현 가능한 Python 소스코드
results/*.csv	성능 비교표 및 분석 결과
figures/*.png	EDA 및 중요도 시각화 결과